Datos Masivos I

3. Búsqueda de elementos similares

Profa. Alondra Berzunza

3. Búsqueda de elementos similares

Un problema fundamental de la minería de datos, es examinar los datos en búsqueda de elementos similares.

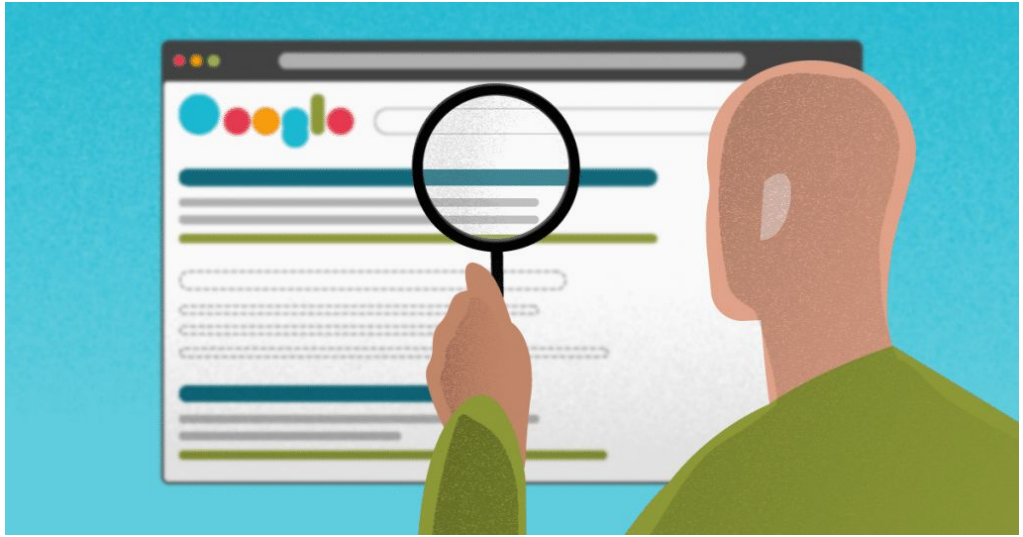

¿Cómo encontramos imágenes?

house

Page 2 of about 413,000,000 results (0.08 seconds)

Related searches: house **tv show** **greg** house house **clipart** **cartoon** house house **music**

Click the Small **House** In The
465 × 346 - 58k - jpg
supercoloring.com
Find similar images

The **house** ...
600 × 400 - 93k - jpg
museumoffloridahistory.com
Find similar images

This large **house** ...
500 × 375 - 43k - jpg
glamro.gov.uk
Find similar images

HouseplanGuys.com, The largest
500 × 300 - 35k - jpg
houseplanguys.com
Find similar images

House picture by atkinson_crystal
800 × 600 - 299k - jpg
s588.photobucket.com
Find similar images

Barack & Michelle Obama P
622 × 402 - 104k - jpg
hiptics.com
Find similar images

Búsqueda de imágenes por color

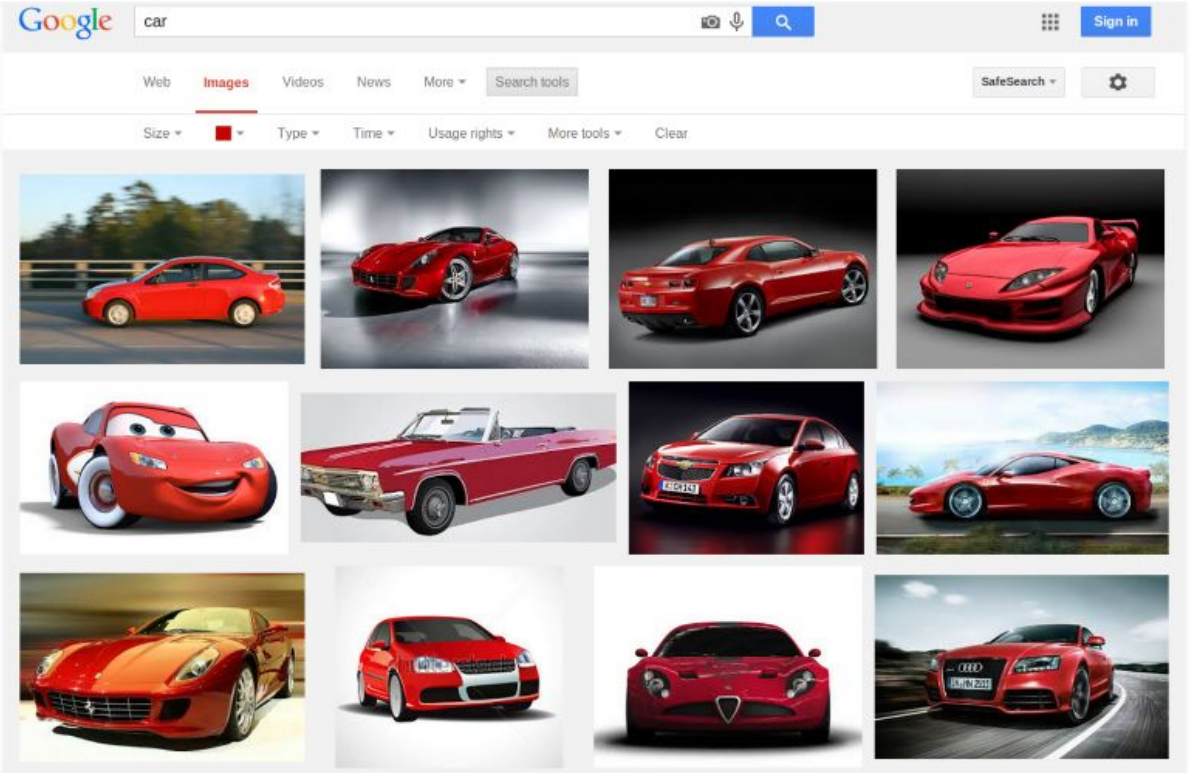

Búsqueda de imágenes por estilo

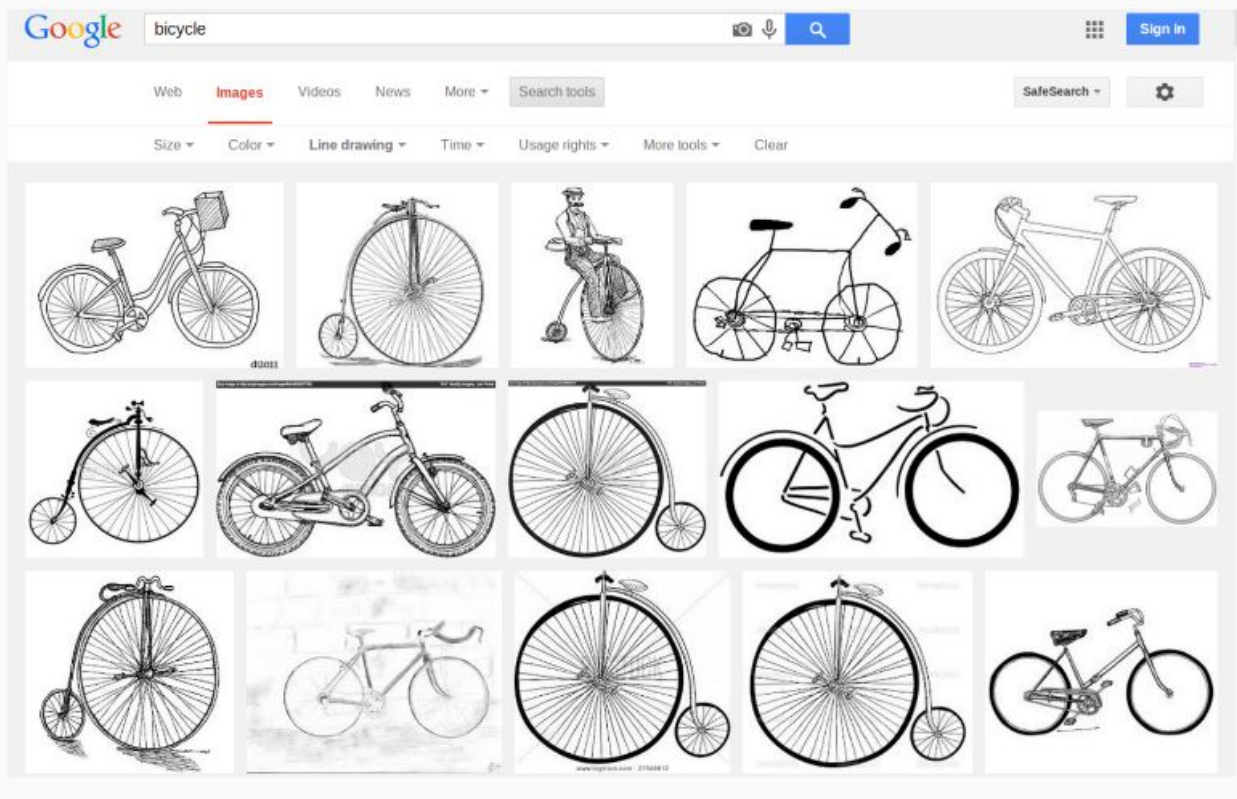

Búsqueda de imágenes con características específicas

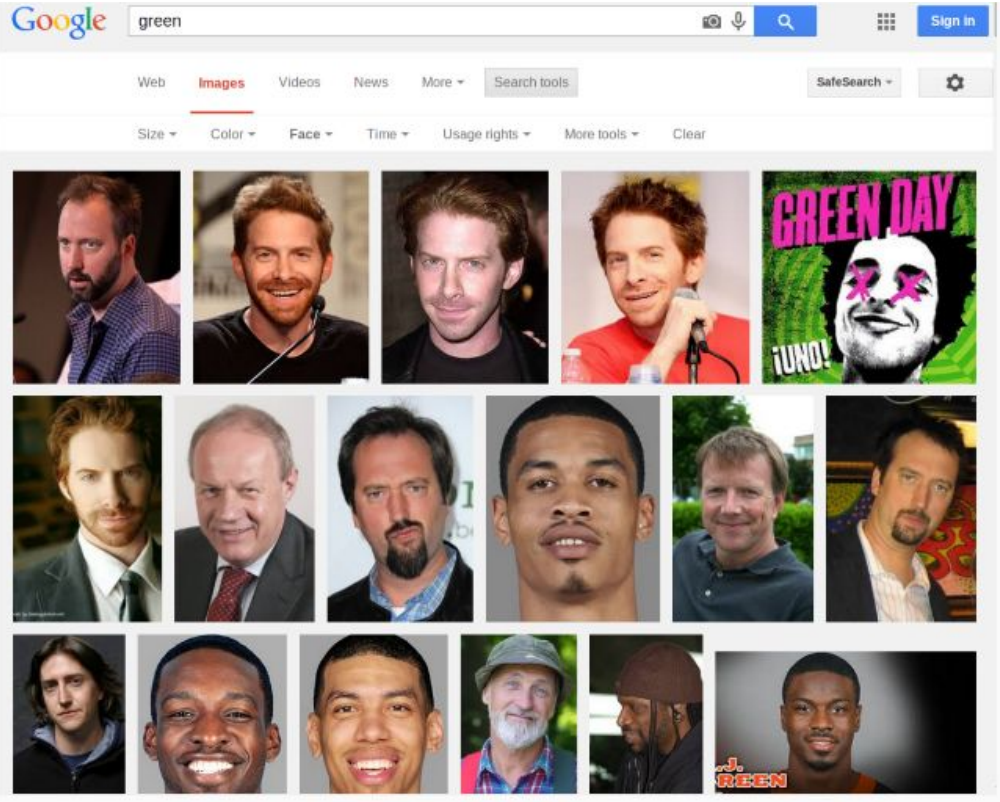

Búsqueda de imágenes visualmente similares

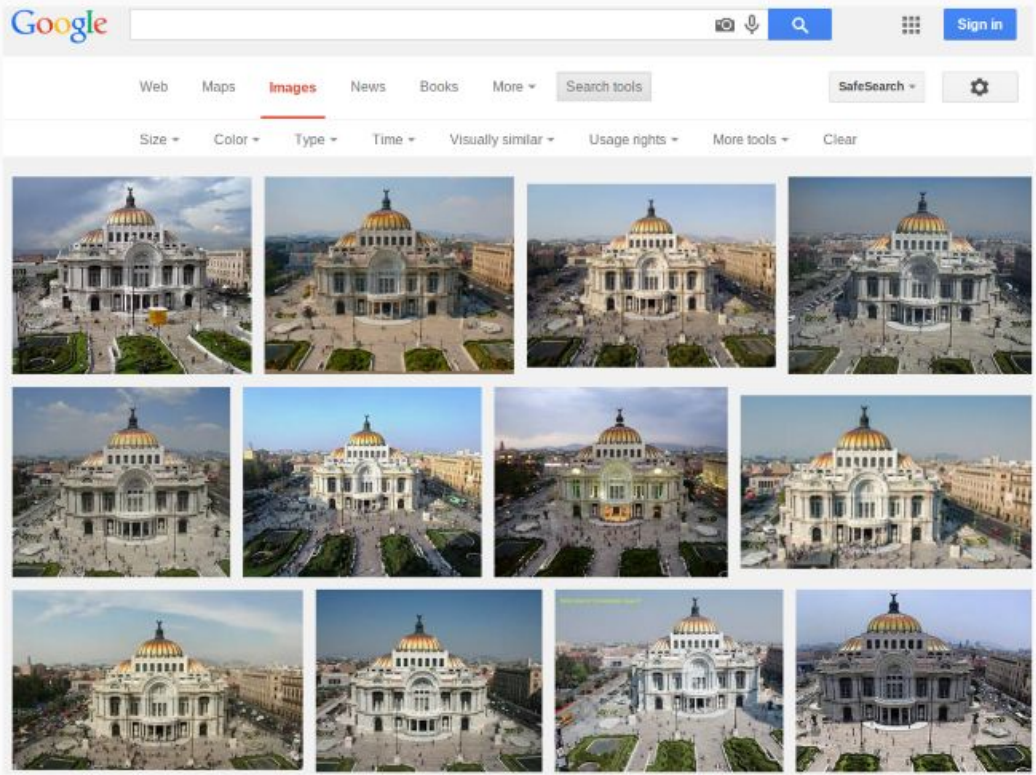

Búsqueda de imágenes de la misma categoría

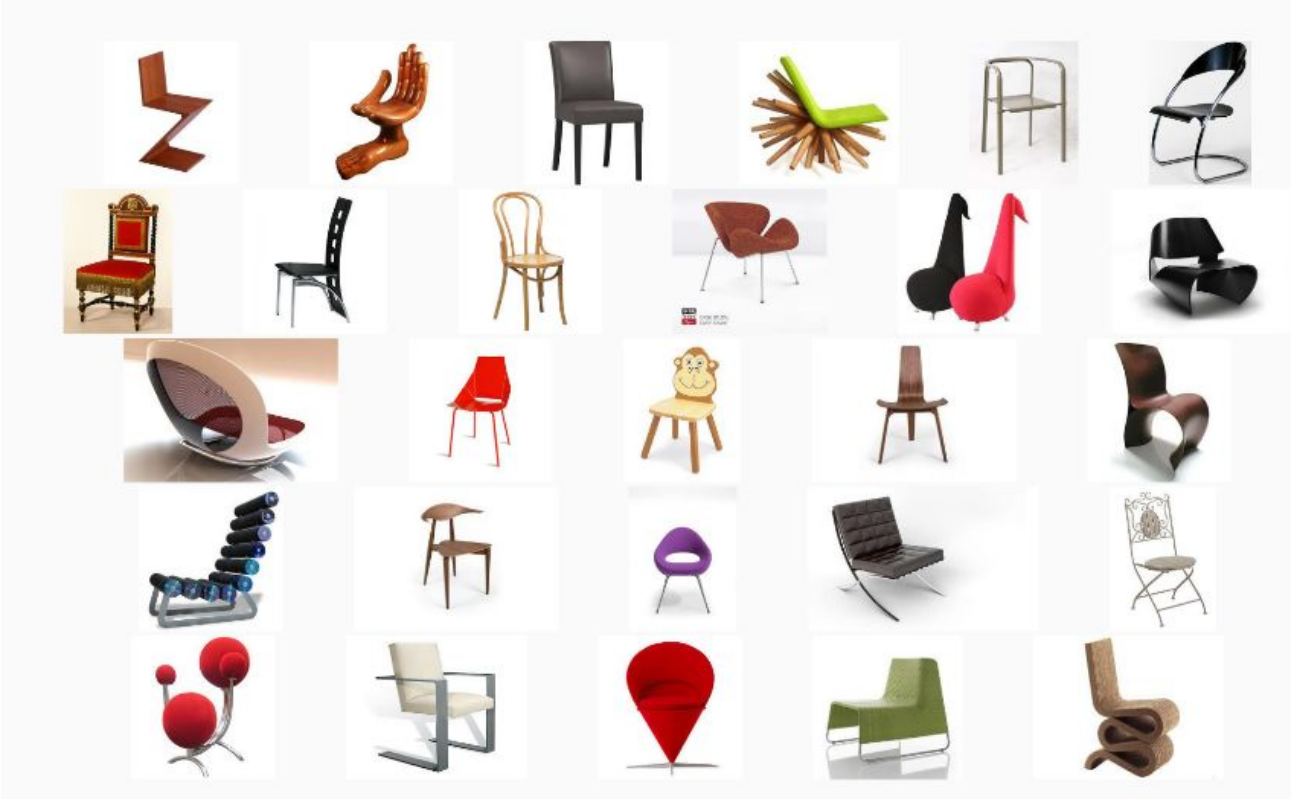

Medidas de similaridad

El problema del vecino más cercano

Tarea frecuente en análisis de datos (por ej. agrupamientos de clientes similares, búsqueda de documentos sobre el mismo tema, etc).

Usado por algunos métodos no paramétricos de aprendizaje de máquina (por ej. clasificador de k-vecinos más cercanos).

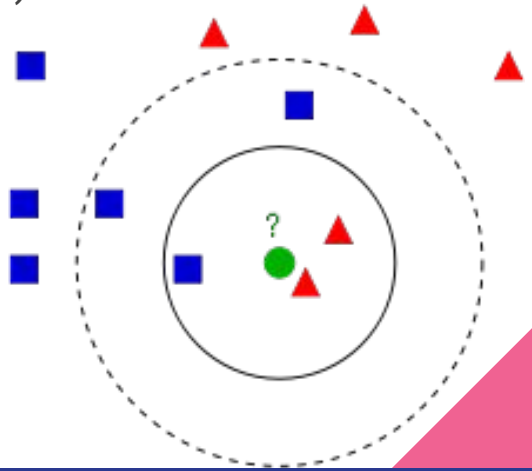

El problema del vecino más cercano

El problema es encontrar el par de objetos $(x^{(1)}, x^{(2)}) \in X$ que son más similares o que son más cercanos bajo algún criterio de similitud o distancia $M(x^{(1)}, x^{(2)})$

Usando fuerza bruta requería comparar todos los pares posibles en *X* lo cual es

$$\frac{n}{2} = \lambda(n^2)$$

Función de Distancia

- Cuantifica la disimilitud entre dos objetos.
- Debe cumplir las siguientes propiedades:
  - No negativo: $dist(x, y) \geq 0$
  - Identidad de los indiscernibles: $dist(x, y) = 0 \Leftrightarrow x = y$
  - Simétrico: $dist(x, y) = dist(y, x)$
  - Desigualdad del triángulo: $dist(x, y) \leq dist(x, z) + dist(z, y)$

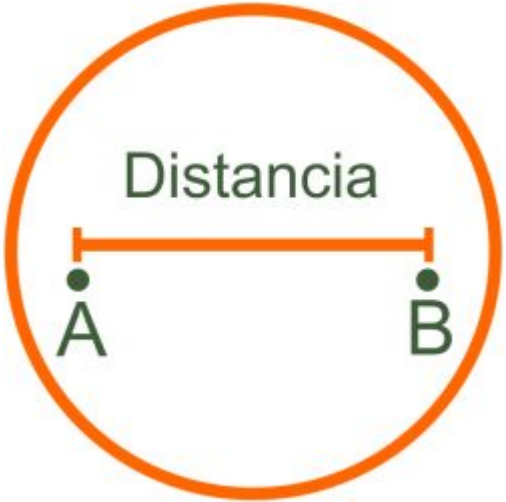

No siempre se mantienen las propiedades de las distancias en la percepción humana. Por ejemplo, la desigualdad del triángulo.

Distancia Euclidiana

Representa el tamaño del segmento de línea que conecta dos puntos **x**, **y**.

$$dist(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{k=1}^{L} (y_k - x_k)^2}$$

Similitud y Distancia coseno

La similitud coseno compara la orientación de dos vectores mediante el coseno del ángulo entre ellos.

$$S_C(\mathbf{x}, \mathbf{y}) = cos(\theta) = \frac{\mathbf{x} \cdot \mathbf{y}}{\|\mathbf{x}\| \cdot \|\mathbf{y}\|} = \frac{\sum_{i=1}^{L} x_i \cdot y_i}{\sqrt{\sum_{i=1}^{L} x_i^2} \cdot \sqrt{\sum_{i=1}^{L} y_i^2}}$$

Dos vectores con la misma orientación tienen una similitud de 1.

Comúnmente usada para comparar documentos de texto.

Distancia Hamming

Para un tamaño fijo T, es el número de elementos distintos de 2 vectores o cadenas.

Ejercicio:

Calcula la distancia de Hamming de los siguientes objetos.

1. ‘asar’ y ‘azar’
2. 57941137 y 23111431
3. 10110010 y 01011110

Similitud y Distancia de Jaccard

Dados 2 conjuntos { $c^{(1)}, c^{(2)}$ } su similitud de Jaccard se define como:

$$J(c^{(1)}, c^{(2)}) = \frac{|c^{(1)} \cap c^{(2)}|}{|c^{(1)} \cup c^{(2)}|} \in [0,1]$$

La distancia de Jaccard es:

$$dist_j(c^{(1)}, c^{(2)}) = 1 - J(c^{(1)}, c^{(2)})$$

Ejercicio:

Calcula la similitud de Jaccard de los conjuntos:

$$c^{(1)} = \{0,3,6,7\} \qquad c^{(2)} = \{2,3,5,7\}$$

Generalización de Similitud de Jaccard para bolsas

$$J(B^{(1)},B^{(2)})=\frac{\sum_{w=1}^{D} min(B_w^{(1)},B_w^{(2)})}{\sum_{w=1}^{D} max(B_w^{(1)},B_w^{(2)})}\in[0,1]$$

Donde $B_w^{(1)},B_w^{(2)}$ son las multiplicidades del elemento **w** en las bolsas $B^{(1)},B^{(2)}$ respectivamente.

La distancia generalizada es $dist_J(B^{(1)},B^{(2)})=1-J(B^{(1)},B^{(2)})$

Ejercicio:

Calcula la similitud generalizada de las siguientes bolsas

$$B^{(1)}=\{(0,2),(3,1),(6,1),(7,3)\}$$

$$B^{(2)}=\{(2,1),(3,2),(5,3),(7,1)\}$$

Traslape de dos Conjuntos

Número de elementos en común sobre mínimo de elementos de dos conjuntos.

$$ovr\left(c^{(1)}, c^{(2)}\right) = \frac{\left|c^{(1)} \cap c^{(2)}\right|}{min\left(\left|c^{(1)}\right|, \left|c^{(2)}\right|\right)}$$

Ejercicio:

Calcula el traslape entre los siguientes pares de conjuntos.

$c^{(1)} = \{0,3,6,7\}$ y $c^{(2)} = \{2,3,5,7\}$

$c^{(1)} = \{0,3,6,7\}$ y $c^{(2)} = \{0,3,7\}$

$c^{(1)} = \{2,3,7\}$ y $c^{(2)} = \{2,3,4,7\}$

Árboles Kd

Árbol binario de k-dimensiones, que sirve para realizar la búsqueda del vecino más cercano.

Cada nivel del árbol se refiere a una dimensión.

Para buscar puntos:

1. Se construye el árbol con el conjunto de puntos disponible
2. Dado un nuevo punto de consulta, se busca el punto más cercano recorriendo el árbol.

Construcción de un árbol

1. Elegir la dimensión de forma alternada (ej. para 2D, la raíz usa X, sus hijos Y, y así sucesivamente).

2. Inserta punto con valor en el criterio establecido (ej. la mediana) de la dimensión seleccionada, puntos menores son descendientes en su rama izquierda y mayores en su derecha.

3. Se repite 1 y 2 para los descendientes hasta que ya no haya más puntos.

Construcción de un árbol

Supongamos que hay 6 puntos de datos bidimensionales

{(2,3), (5,4), (9,6), (4,7), (8,1), (7,2)},

y los puntos de datos están ubicados en pares dentro del espacio dimensional.

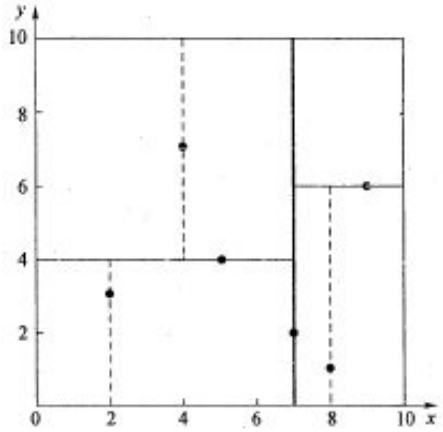

Construcción de un árbol

{(2,3), (5,4), (9,6), (4,7), (8,1), (7,2)}

1. Determine el primer valor del dominio dividido. Calcule la varianza de los datos en x y de los datos en y.

   Nos damos cuenta que el que tiene mayor varianza es x, por lo que el valor del dominio dividido se toma primero como 0, que es la dirección del eje x.

2. Determine el valor de dominio de datos de nodo. De acuerdo con los valores en la dirección del eje x 2,5,9,4,8,7.

   El valor medio es 7, por lo que los datos de nodo = (7,2).
   De esta manera, el hiperplano de segmentación de este nodo es una línea recta x = 7 que pasa a través de (7, 2) y perpendicular a split = 0 (eje x);

Construcción de un árbol

3. Determine los subespacios izquierdo y derecho. Dividir el hiperplano x = 7 divide todo el espacio en dos partes. La parte de x <= 7 es el subespacio izquierdo, que contiene 3 nodos {(2,3), (5,4), (4,7)}; la otra parte es el subespacio derecho, que contiene 2 nodos {(9, 6), (8,1)}.

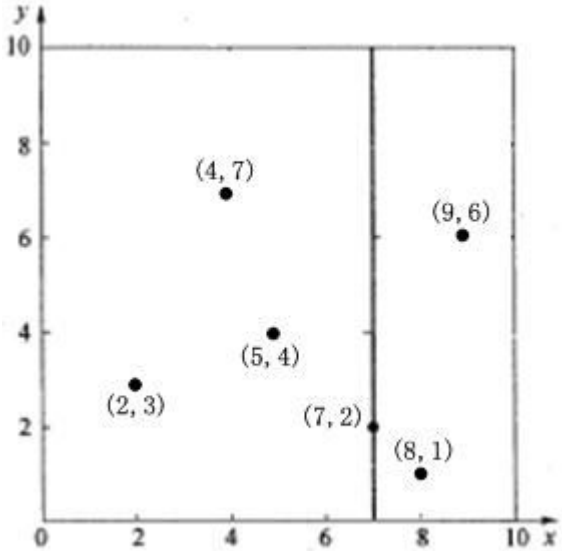

Construcción de un árbol

Como se indica en el algoritmo, la construcción del árbol Kd es un proceso recursivo. El mismo proceso se debe aplicar para los subespacios.

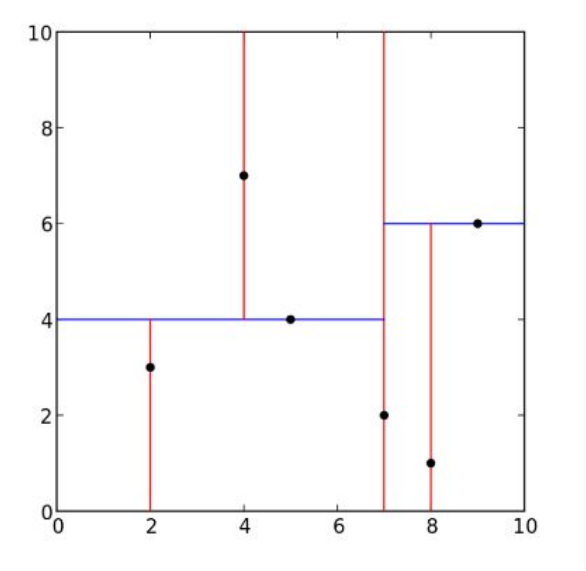

Construcción de un árbol

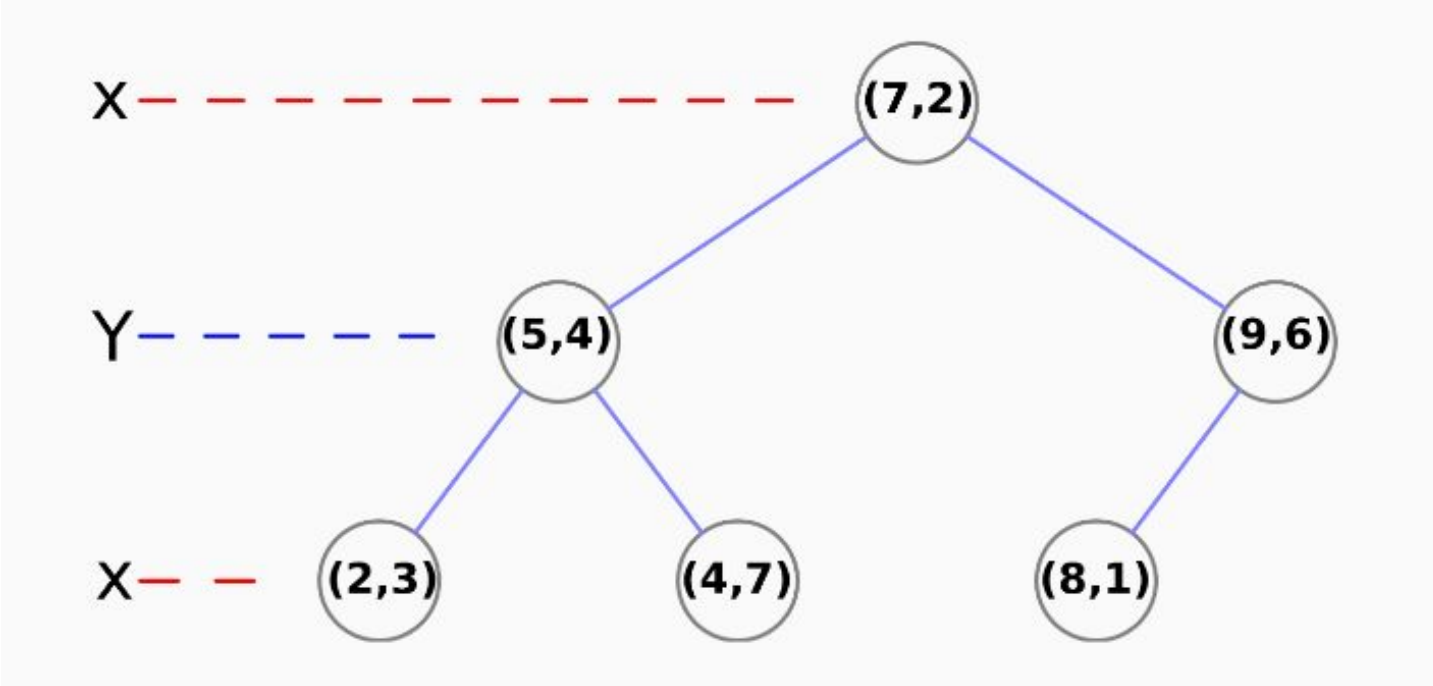

Inserción de puntos al árbol

1. Recorre el árbol a partir de la raíz moviéndose hacia el descendiente correspondiente.

2. Cuando se encuentra el nodo padre el punto a insertar, se agrega a la derecha o a la izquierda, dependiendo del valor de la dimensión de partición.

3. En caso de estar desbalanceado, se aplica un algoritmo de re-balanceo para evitar pérdida de rendimiento.

Búsqueda del vecino más cercano en árboles Kd

Se recorre el árbol a partir de la raíz y moviéndose hacia el descendiente correspondiente.

- Se mantiene el punto más cercano C_{min} y quita los nodos del árbol que están más alejados de este.
- Recorre los subárboles/ subespacios restantes.

Sufre la maldición de la dimensionalidad

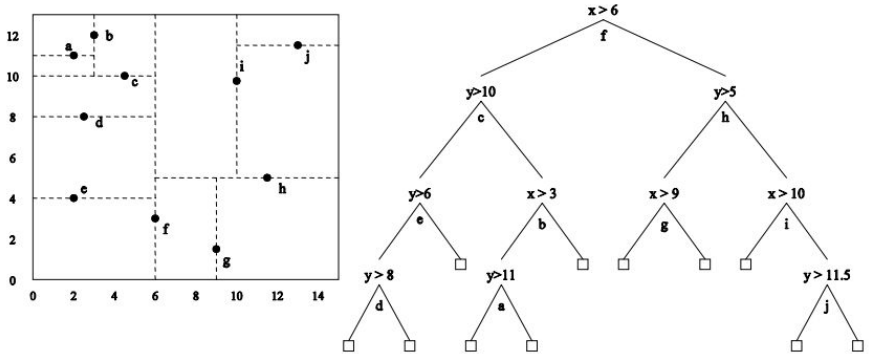

Búsqueda del vecino más cercano en árboles Kd

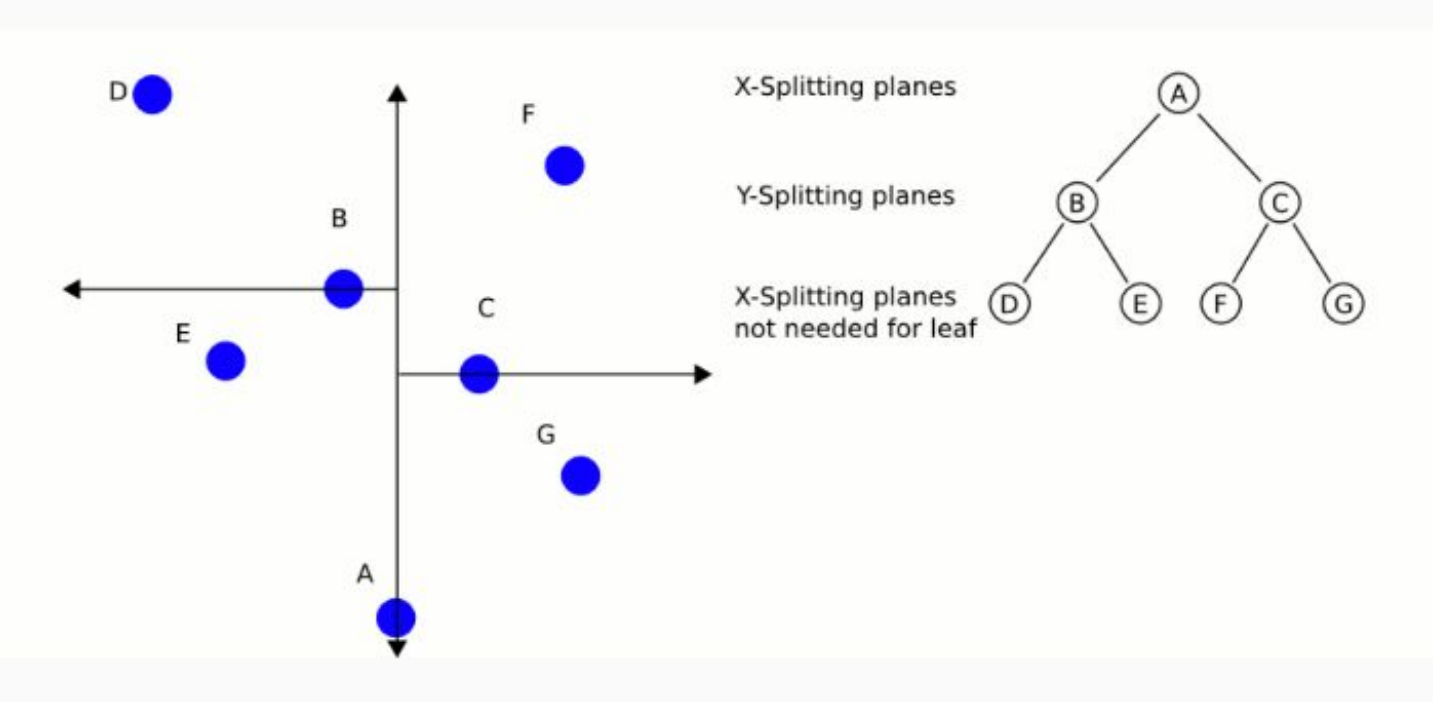

Búsqueda del vecino más cercano en árboles Kd

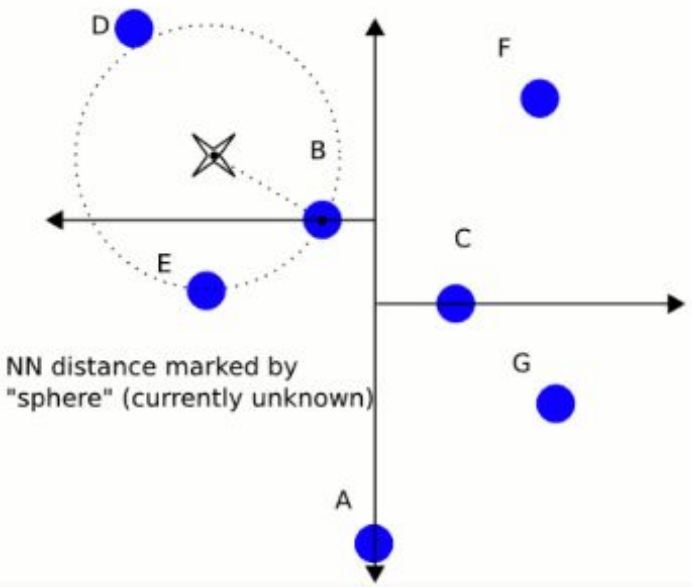

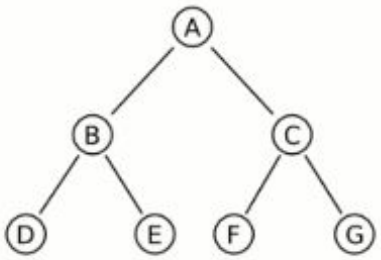

Búsqueda del vecino más cercano en árboles Kd

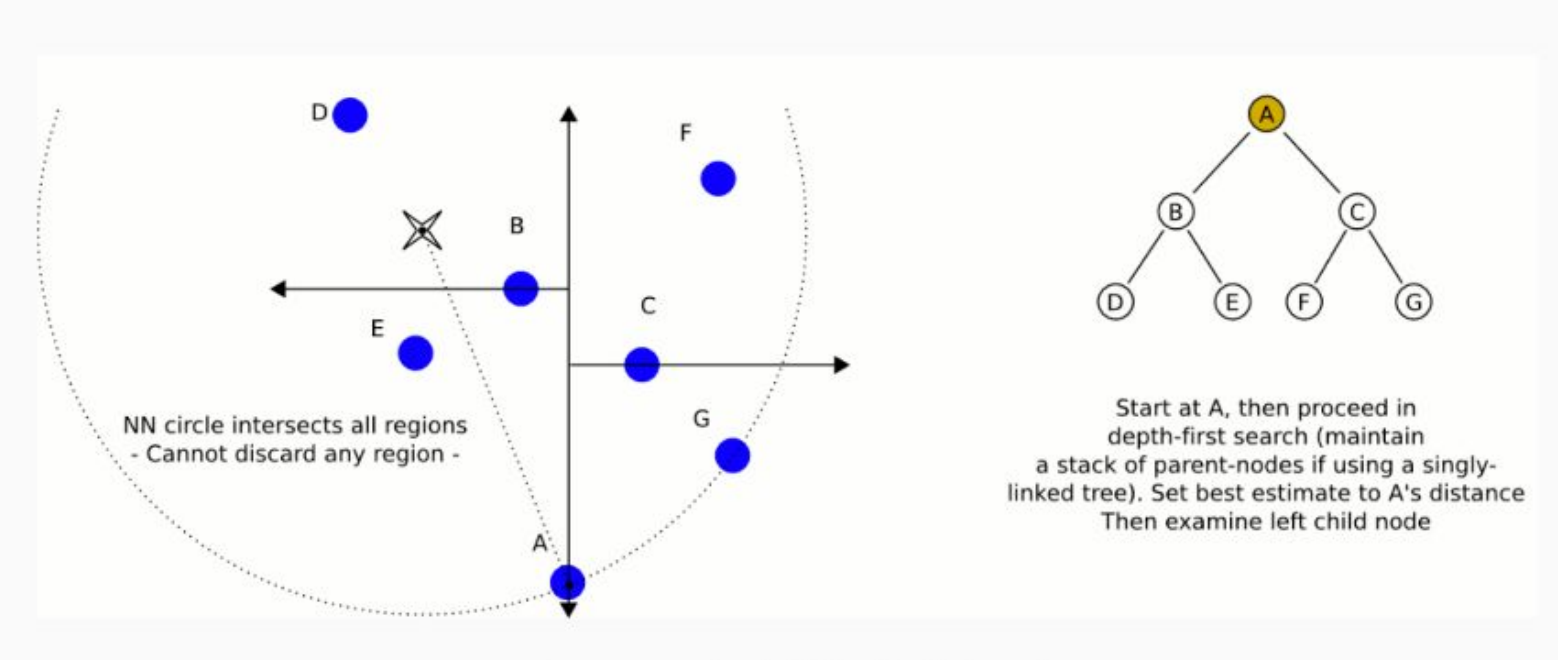

Búsqueda del vecino más cercano en árboles Kd

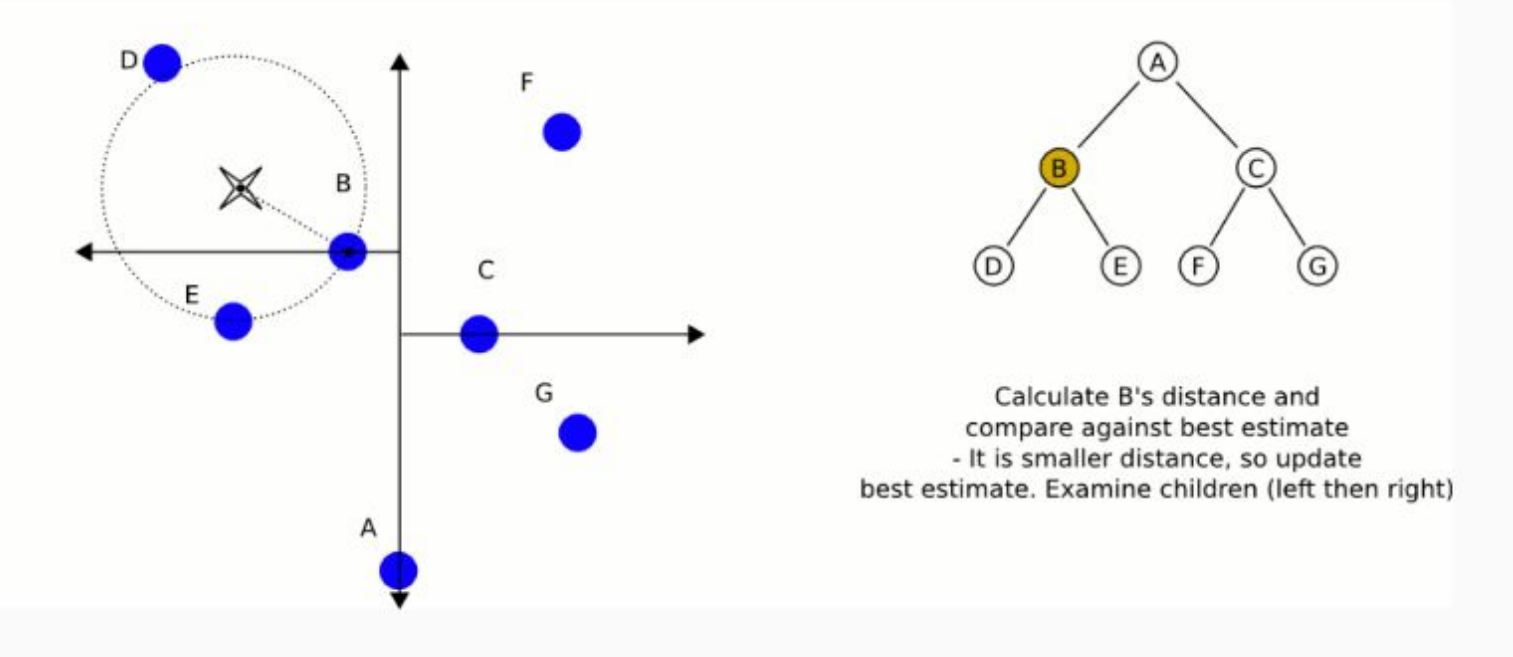

Búsqueda del vecino más cercano en árboles Kd

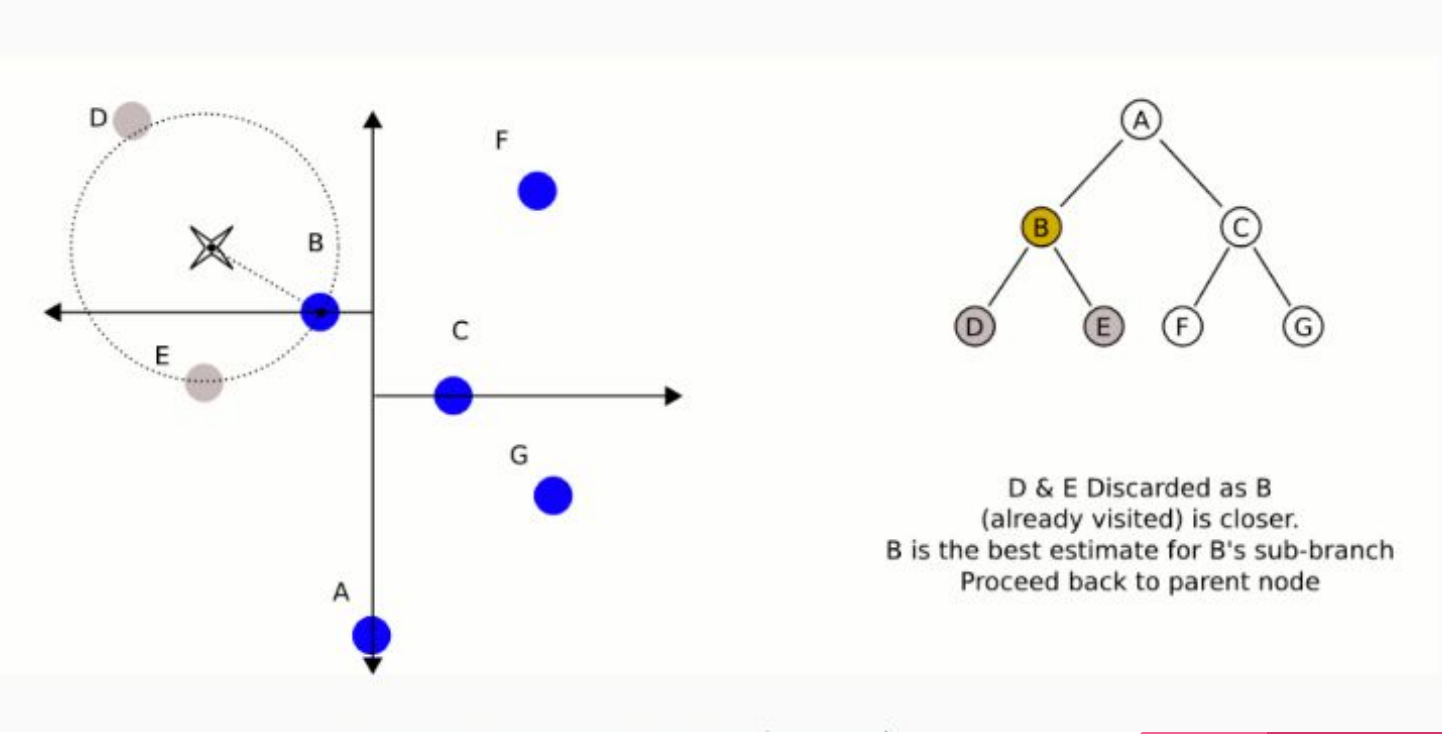

Ejercicio

- Construye el árbol binario Kd para el siguiente conjunto de puntos en 2D.

  { (8.3, 3.0), (6.2, 2.4), (0.2, 4.3), (7.5, 1.6), (3.6, 0.2), (2.5, 8.8), (1.7, 5.1) }

- Dibuja la partición correspondiente del plano.

- Busca los vecinos más cercanos en X de los siguientes puntos:

  { (9.8, 1.7), (3.3, 9.6), (8.1, 1.2)}

Maldición de la dimensionalidad

A medida que aumenta el número de dimensiones, la distancias se vuelven menos discriminativas.

En Machine Learning, el número de dimensiones se puede equiparar al número de variables o características que estemos utilizando.

La maldición de la dimensión se «manifiesta» de dos maneras:

- La distancia media entre los datos aumenta con el número de dimensiones
- **La variabilidad de la distancia disminuye exponencialmente con el número de dimensiones**

Maldición de la dimensionalidad

A medida que el número de dimensiones aumenta, la distancia media entre ellos también aumenta.

Esto en sí mismo no es muy problemático para el aprendizaje automático.

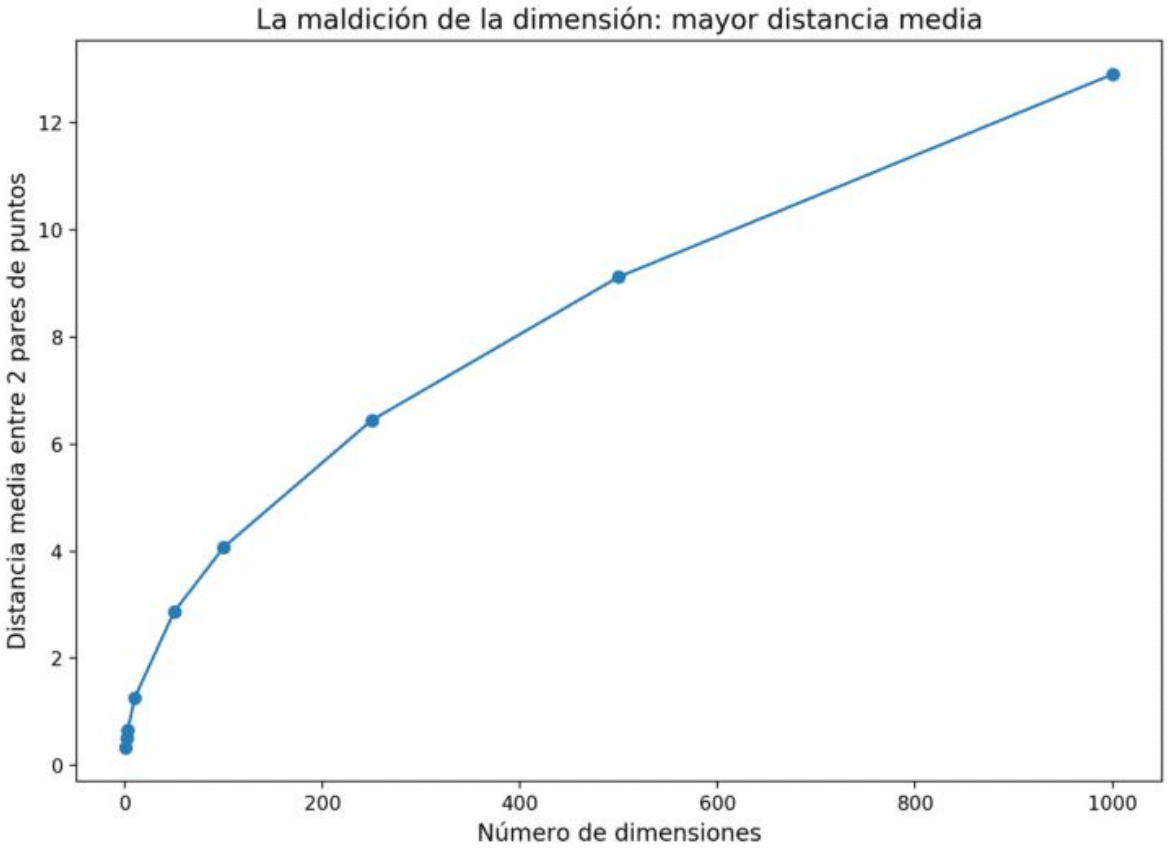

Maldición de la dimensionalidad

Lo verdaderamente importante es que a medida que el número de dimensiones aumenta, la variabilidad de las distancias entre los datos disminuye exponencialmente.

El gráfico muestra el coeficiente de variación para varias dimensiones (hasta 1000). El coeficiente de variación se utiliza para medir la variabilidad.

El problema es que cuando hay un gran número de atributos (features), los datos están todos a casi la misma distancia. Es decir, no hay variabilidad entre sus distancias.

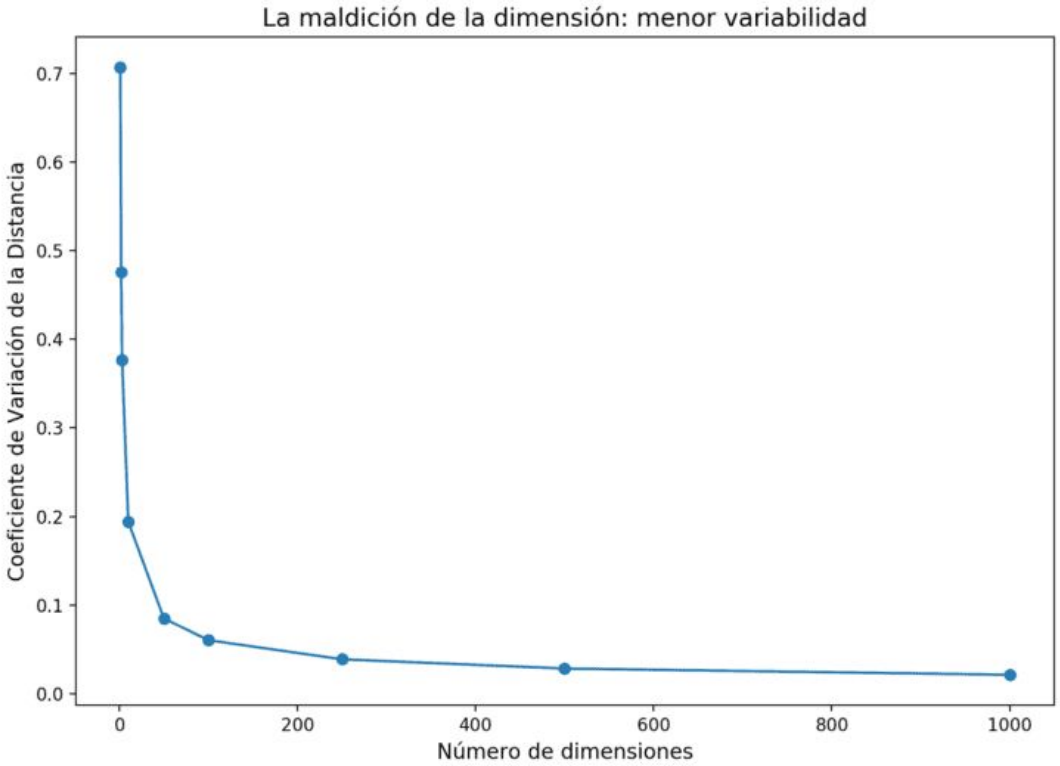

Maldición de la dimensionalidad

La maldición de la dimensión es un concepto un tanto abstracto, por eso es necesario observar lo que sucede cuando se aumenta el número de variables.

La figura muestra la distribución de distancias euclídeas entre 10000 puntos aleatorios en el rango [0, 1] en varias dimensiones: 1, 2, 3, 10, 50, 100, 250, 500 y 1000.

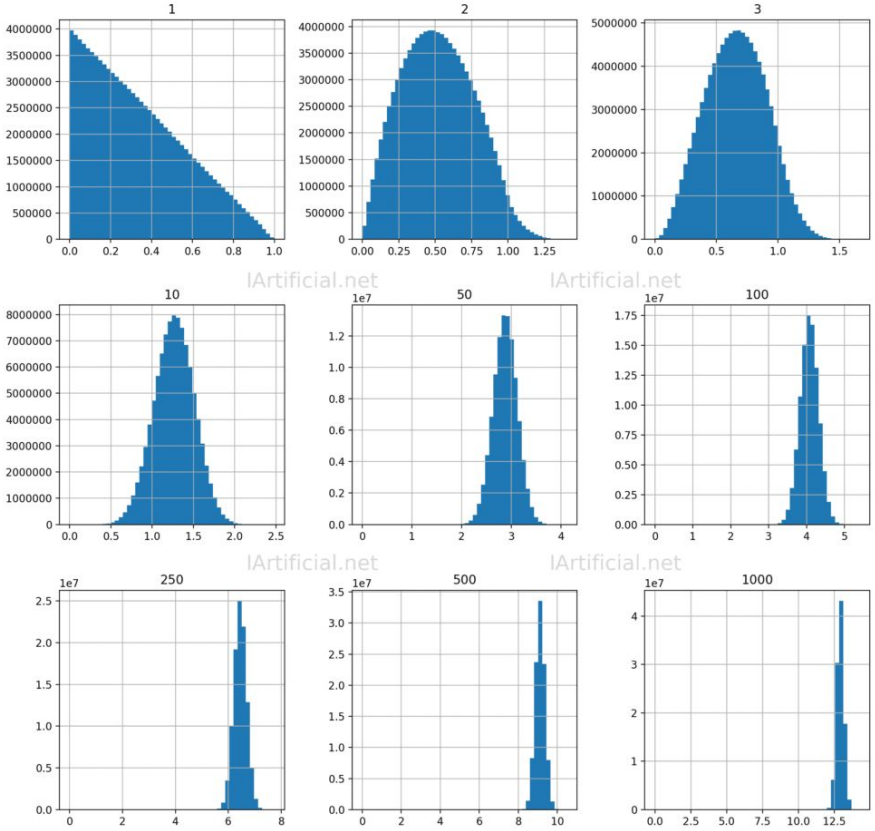

Maldición de la dimensionalidad

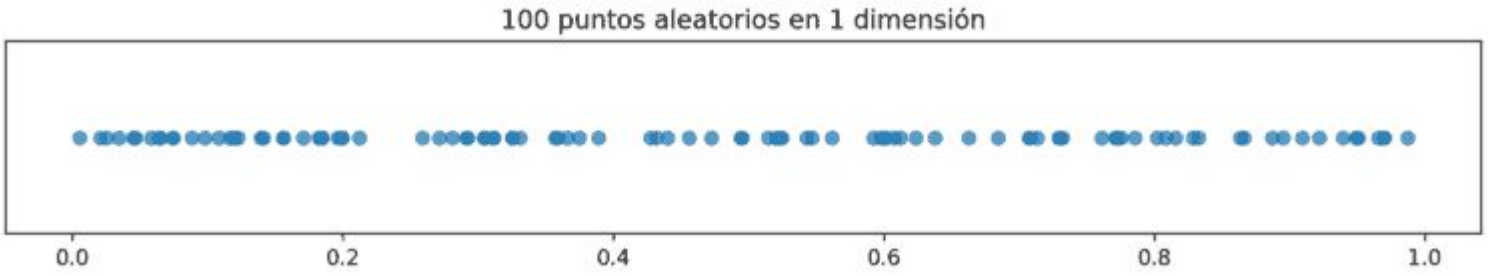

La maldición de la dimensión sólo afecta a las técnicas basadas en distancias.

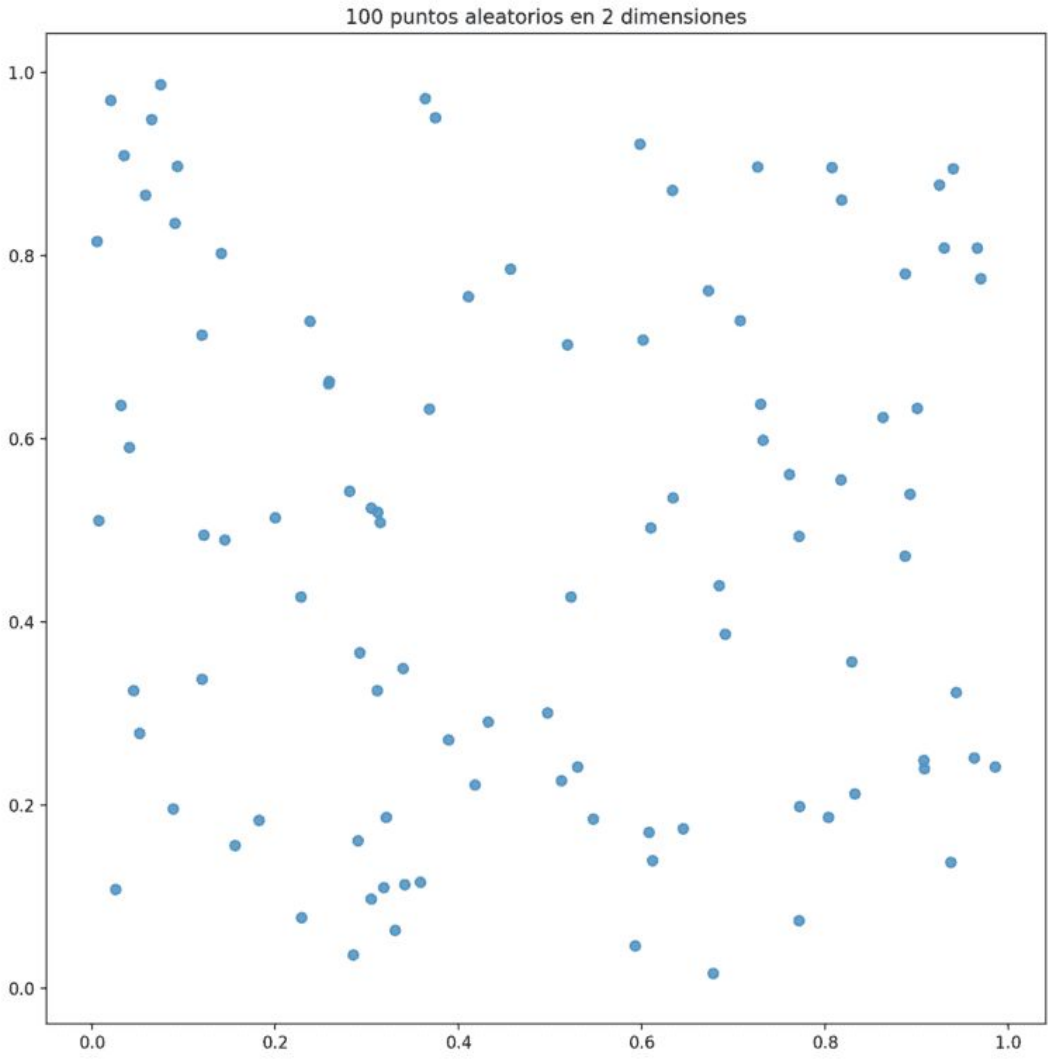

Maldición de la dimensionalidad

Para mitigar el efecto de la maldición de la dimensión tenemos dos opciones:

- reducir el número de dimensiones
- aumentar la cantidad de datos